Analisis Hubungan & Korelasi

Nama: Derayan Bima A

Dosen Pengampu: Undang Syaripudin, Ph.D., M.Kom.

1. Tujuan dan data

Laporan ini menyelesaikan lima metode korelasi yang diminta dalam tugas: Point-Biserial, Koefisien Kontingensi, Phi, Spearman Rank, dan Product Moment Pearson.

Dataset terdiri dari 36 task migrasi UI dan beberapa observasi eksekusi untuk setiap task. Agar satu task tidak dihitung berkali-kali sebagai observasi independen, nilai numerik dirata-ratakan berdasarkan **ticket_id** sebelum analisis hubungan dilakukan.

> Catatan penting: execution time, token usage, accuracy score, test pass rate, dan error count merupakan data sintetis untuk pembelajaran. Hasil tidak boleh dianggap sebagai performa AI nyata, benchmark Codex, atau performa produksi.

2. Ringkasan hasil

Metode	Variabel yang diuji	n	Koefisien	p-value	Keputusan
Point-Biserial	is_hard (Easy vs Hard) and mean execution_time_sec	17	0,9526	<0,001	Signifikan
Contingency Coefficient (CC)	component_area and difficulty	36	0,3376	0,9144	Tidak signifikan
Phi (phi)	is_hard (Hard vs non-Hard) and has_error	36	0,1870	0,2619	Tidak signifikan
Spearman Rank	difficulty rank (Easy=1, Medium=2, Hard=3) and mean execution_time_sec	36	0,9045	<0,001	Signifikan
Pearson Product-Moment	mean execution_time_sec and mean token_usage	36	0,9608	<0,001	Signifikan

3. Penjelasan cara kerja setiap metode

A. Korelasi Point-Biserial
Kapan digunakan: satu variabel kategorikal nominal dengan tepat dua kategori dan satu variabel numerik kontinu.
Cara kerja: data kategori diubah menjadi kode 0 dan 1. Kemudian rata-rata variabel numerik pada kelompok 0 dan kelompok 1 dibandingkan, lalu perbedaan tersebut disesuaikan dengan simpangan baku dan proporsi kedua kelompok.
Rumus: r_pb = ((M1 - M0) / s_y) x akar(pq).
Penerapan: Easy versus Hard dibandingkan dengan rata-rata execution time. Koefisien = **0,9526**, p-value = **<0,001**. Hard task memiliki waktu rata-rata 130,75 detik, sedangkan Easy task 52,51 detik. Hubungan sangat kuat dan signifikan pada sampel sintetis ini.

B. Korelasi Kontingensi (CC)
Kapan digunakan: dua variabel kategorikal dengan dua kategori atau lebih. Metode ini memakai tabel kontingensi dan statistik chi-square.
Cara kerja: frekuensi aktual setiap kombinasi kategori dibandingkan dengan frekuensi harapan. Nilai chi-square kemudian diubah menjadi koefisien CC.
Rumus: CC = akar(chi-square / (chi-square + N)).
Penerapan: component_area dibandingkan dengan difficulty. Koefisien = **0,3376**, p-value = **0,9144**. Hubungan tidak signifikan.

C. Korelasi Phi
Kapan digunakan: dua variabel kategorikal yang masing-masing hanya memiliki dua kategori, sehingga membentuk tabel 2 x 2.
Cara kerja: empat frekuensi sel tabel 2 x 2 digunakan untuk membandingkan pola kemunculan kedua variabel. Nilai Phi juga berkaitan langsung dengan chi-square pada tabel 2 x 2.
Rumus: phi = (ad - bc) / akar((a+b)(c+d)(a+c)(b+d)).
Penerapan: is_hard dibandingkan dengan has_error. Koefisien = **0,1870**, p-value = **0,2619**. Hubungan lemah dan tidak signifikan.

3. Penjelasan cara kerja setiap metode (lanjutan)

D. Korelasi Spearman Rank
Kapan digunakan: dua variabel ordinal atau hubungan yang ingin dinilai berdasarkan urutan/ranking. Metode ini tidak menuntut hubungan linear dan lebih fleksibel terhadap outlier dibanding Pearson.
Cara kerja: setiap nilai diubah menjadi ranking. Selisih ranking untuk setiap pasangan dihitung, dikuadratkan, lalu dijumlahkan. Semakin konsisten urutan kedua variabel, semakin besar nilai rho.
Rumus: rho = 1 - 6 jumlah(d^2) / (n(n^2 - 1)).
Penerapan: difficulty diubah menjadi Easy=1, Medium=2, Hard=3 dan dibandingkan dengan execution time. Koefisien = **0,9045**, p-value = **<0,001**. Terdapat hubungan positif yang sangat kuat dan signifikan.

E. Korelasi Product Moment Pearson
Kapan digunakan: dua variabel numerik kontinu dengan fokus pada hubungan linear.
Cara kerja: setiap nilai dibandingkan dengan rata-ratanya untuk memperoleh kovarians. Kovarians tersebut dibagi dengan perkalian simpangan baku kedua variabel, sehingga koefisien berada pada rentang -1 sampai +1.
Penerapan: mean execution time dibandingkan dengan mean token usage. Koefisien = **0,9608**, p-value = **<0,001**. Hubungan linear positif sangat kuat dan signifikan.

4. Pemilihan metode yang tepat

Jenis variabel	Metode yang sesuai	Contoh pada dataset
Biner + numerik	Point-Biserial	Easy/Hard + execution time
Kategorikal multi-kategori	Contingency Coefficient	component_area + difficulty
Biner + biner	Phi	is_hard + has_error
Ordinal atau hubungan monotonik	Spearman Rank	difficulty rank + execution time
Numerik kontinu + numerik kontinu	Pearson	execution time + token usage

5. Kesimpulan akhir

Tidak ada satu metode korelasi yang selalu paling baik. Pemilihannya harus mengikuti skala pengukuran variabel. Pada dataset ini, Pearson paling tepat untuk dua metrik kontinu seperti execution time dan token usage. Spearman tepat untuk difficulty yang bersifat berurutan. Contingency Coefficient tepat untuk variabel kategorikal dengan banyak kategori. Phi hanya digunakan untuk dua variabel biner, sedangkan Point-Biserial digunakan untuk satu variabel biner dan satu variabel numerik. Semua interpretasi dibatasi pada dataset sintetis yang dianalisis.

Laporan ini dibuat dari script reproducible **analysis/correlation_analysis.py**. Hasil numerik lengkap tersedia dalam file CSV pendamping.