Visualisasi Perhitungan Korelasi

Laporan tugas - Bahasa Indonesia

Tujuan visual

Dokumen ini menjelaskan bukan hanya kapan setiap metode digunakan, tetapi juga bagaimana data bergerak dari tipe variabel, tabel atau ranking, rumus, sampai interpretasi koefisien.

> Semua nilai numerik berasal dari dataset sintetis. Observasi berulang dirata-ratakan berdasarkan ticket_id sehingga unit analisis untuk metrik eksekusi adalah satu task.

Peta pemilihan metode

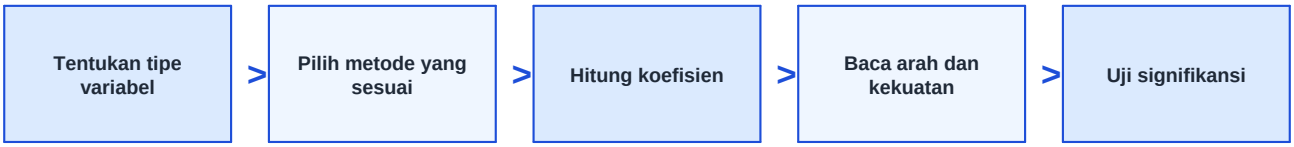

Biner + numerik	Point-Biserial
Kategori multi-level	Koefisien Kontingensi
Biner + biner	Phi
Ordinal / ranking	Spearman Rank
Numerik kontinu + kontinu	Pearson Product Moment

Skala umum koefisien

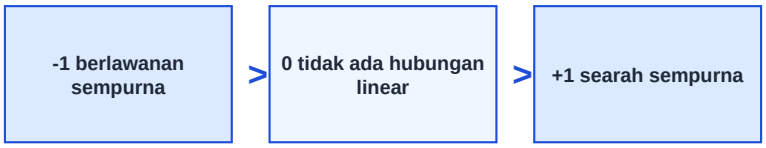

1. Korelasi Point-Biserial

Membandingkan kelompok biner dengan variabel numerik.

Tipe X	Nominal dikotomis: Easy / Hard
Tipe Y	Numerik kontinu: execution_time_sec
Dataset	17 task Easy dan Hard

Visual alur perhitungan

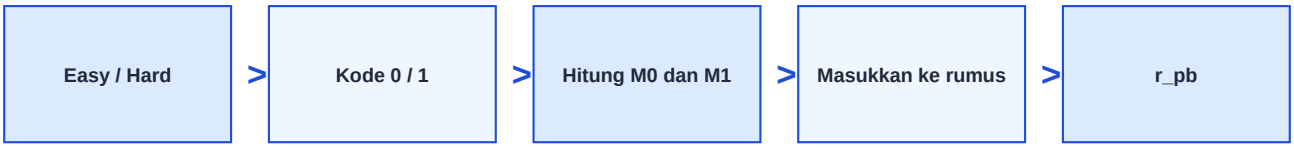

r_pb = ((M1 - M0) / s_y) x akar(pq)

Makna rumus: M1 dan M0 adalah rata-rata Y pada dua kelompok; s_y adalah simpangan baku Y; p dan q adalah proporsi kelompok.

Langkah menghitung

1. Ubah kategori Easy dan Hard menjadi kode biner, misalnya Easy=0 dan Hard=1.

2. Hitung rata-rata execution time untuk masing-masing kelompok: M0 dan M1.

3. Hitung simpangan baku seluruh execution time serta proporsi p dan q.

4. Substitusikan semua komponen ke rumus. Tanda koefisien menunjukkan arah hubungan; nilai absolut mendekati 1 berarti hubungan kuat.

Hasil pada dataset

r_pb = **0,9526**, p-value = **<0,001**. Rata-rata Easy = 52,51 detik dan Hard = 130,75 detik. Hubungan sangat kuat dan signifikan pada sampel sintetis.

2. Koefisien Kontingensi (CC)

Mengukur hubungan antara dua variabel kategorikal.

Tipe X	Kategorikal: component_area
Tipe Y	Kategorikal: difficulty
Dataset	36 task pada katalog

Visual alur perhitungan

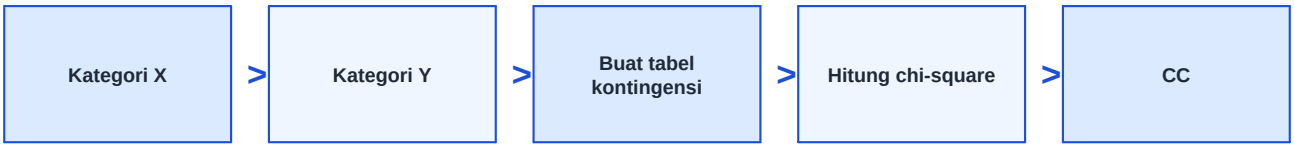

CC = akar(chi-square / (chi-square + N))

Makna rumus: chi-square mengukur perbedaan antara frekuensi aktual dan frekuensi harapan; N adalah jumlah seluruh observasi.

Langkah menghitung

1. Susun baris dan kolom berdasarkan kategori kedua variabel.

2. Isi setiap sel dengan jumlah task pada kombinasi kategori tersebut.

3. Hitung frekuensi harapan dan chi-square.

4. Masukkan chi-square dan N ke rumus CC. Koefisien CC tidak memiliki arah positif/negatif seperti Pearson.

component_area	difficulty
App Bar, Balance, ...	Easy, Medium, Hard

Hasil pada dataset

CC = **0,3376**, p-value = **0,9144**. Hubungan component_area dan difficulty tidak signifikan.

3. Korelasi Phi

Khusus untuk dua variabel biner dengan tabel 2 x 2.

Tipe X	Biner: Hard / Non-Hard
Tipe Y	Biner: Ada error / Tanpa error
Dataset	36 task setelah agregasi

Visual alur perhitungan

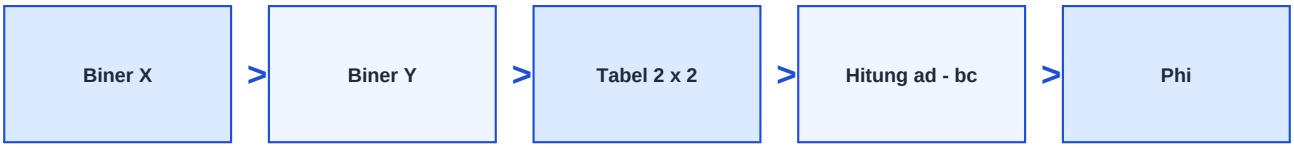

phi = (ad - bc) / akar((a+b)(c+d)(a+c)(b+d))

Makna rumus: a, b, c, dan d adalah empat frekuensi pada tabel 2 x 2. Nilai absolut mendekati 1 menunjukkan hubungan biner yang kuat.

Langkah menghitung

1. Pastikan kedua variabel hanya memiliki dua kategori.

2. Buat tabel 2 x 2 dan isi empat frekuensi a, b, c, d.

3. Hitung pembilang ad-bc dan penyebut dari total marginal tabel.

4. Bagi pembilang dengan penyebut untuk memperoleh Phi, lalu evaluasi p-value dari chi-square.

	Tanpa error	Ada error
Non-Hard	3	23
Hard	0	10

Hasil pada dataset

phi = **0,1870**, p-value = **0,2619**. Hubungan Hard/Non-Hard dengan keberadaan error lemah dan tidak signifikan.

4. Korelasi Spearman Rank

Mengukur hubungan berdasarkan urutan atau ranking.

Tipe X	Ordinal: Easy < Medium < Hard
Tipe Y	Numerik yang dapat diurutkan
Dataset	Difficulty dan execution time

Visual alur perhitungan

rho = 1 - 6 jumlah(d^2) / (n(n^2 - 1))

Makna rumus: d adalah selisih ranking setiap pasangan; n adalah jumlah pasangan observasi. Pada data dengan ties, perangkat lunak memakai average rank.

Langkah menghitung

1. Ubah nilai setiap variabel menjadi ranking.

2. Pasangkan ranking X dan ranking Y untuk setiap task.

3. Hitung d, kuadratkan menjadi d^2, lalu jumlahkan seluruh d^2.

4. Gunakan rumus rho. Nilai positif tinggi berarti task yang lebih sulit cenderung memiliki execution time lebih tinggi.

Difficulty	Ranking	Contoh d
Easy	1	rank X - rank Y
Medium	2	d lalu d^2
Hard	3	jumlahkan semua d^2

Hasil pada dataset

rho = **0,9045**, p-value = **<0,001**. Hubungan difficulty rank dan execution time sangat kuat serta signifikan.

5. Korelasi Product Moment Pearson

Mengukur kekuatan dan arah hubungan linear dua variabel numerik.

Tipe X	Numerik kontinu: execution time
Tipe Y	Numerik kontinu: token usage
Dataset	36 rata-rata task

Visual alur perhitungan

r = kovarians(X,Y) / (s_x x s_y)

Makna rumus: Kovarians menunjukkan apakah X dan Y bergerak bersama; s_x dan s_y menormalisasi skala agar koefisien berada dari -1 sampai +1.

Langkah menghitung

1. Hitung rata-rata X dan Y.

2. Untuk setiap task, hitung deviasi X dari rata-ratanya dan deviasi Y dari rata-ratanya.

3. Kalikan deviasi berpasangan untuk memperoleh kovarians.

4. Bagi kovarians dengan perkalian simpangan baku X dan Y. Nilai positif berarti keduanya cenderung naik bersama.

X	Y	Tujuan
execution_time_sec	token_usage	Menguji pola linear
Numerik kontinu	Numerik kontinu	Satu task = satu titik

Hasil pada dataset

r = **0,9608**, p-value = **<0,001**. Execution time dan token usage memiliki hubungan linear positif yang sangat kuat dan signifikan.