LAPORAN UJI NON-PARAMETRIK

Mann-Whitney, Wilcoxon, Kruskal-Wallis, dan Chi-Square

Mata kuliah	Statistics for Data Science
Tugas	Non-Parametric Test
Nama	Derayan Bima Alamsyah
Tanggal	22 Oktober 2026
Dataset	Synthetic Android UI migration dataset

Empat uji non-parametrik diterapkan pada dataset migrasi Android sintetis. Pada alpha = 0.05, Mann-Whitney dan Chi-Square menolak H0, sedangkan Wilcoxon dan Kruskal-Wallis belum memberikan bukti yang cukup untuk menolak H0.

Laporan ini hanya menjelaskan pola dalam sampel sintetis yang tersedia. Nilai waktu eksekusi, token, akurasi, pass rate, dan error count adalah data simulasi untuk pembelajaran, bukan pengukuran agent AI atau benchmark produksi.

1. Dataset dan rancangan analisis

Analisis menggunakan data/migration_tasks.csv yang berisi 36 task dan data/migration_observations.csv yang berisi 180 observasi. Setiap task memiliki lima pengulangan eksekusi sintetis. Untuk uji yang menggunakan task sebagai unit analisis, lima pengulangan dirata-ratakan berdasarkan ticket_id agar satu task tidak dihitung sebagai lima sampel independen.

Metode	Perbandingan	Unit analisis
Mann-Whitney U	Waktu Hard vs Easy	Satu mean task-level per task
Wilcoxon signed-rank	Akurasi agent A vs B	Satu pasangan matched task
Kruskal-Wallis H	Waktu antar-component area	Satu mean task-level per task
Chi-Square independence	Difficulty vs status mayoritas	Satu status mayoritas per task

Semua pengujian bersifat dua sisi dengan alpha = 0.05. Effect size disertakan agar keputusan p-value tidak dibaca sebagai ukuran besar-kecilnya perbedaan secara otomatis.

2. Ringkasan hasil

Uji	Statistik	df	p-value	Effect size	Keputusan
Mann-Whitney U	U = 70.000	-	0.0001028	Rank-biserial correlation = 1.000	Reject H0
Wilcoxon signed-rank	W = 286.500	-	0.6406	Matched-pairs rank-biserial correlation = 0.090	Fail to reject H0
Kruskal-Wallis H	H = 8.184	5	0.1464	Epsilon-squared = 0.106	Fail to reject H0
Chi-Square test of independence	chi-square = 31.535	2	1.42e-07	Cramer's V = 0.936	Reject H0

Ringkasan kelompok

Test	Kelompok	n	Mean	Median
Mann-Whitney	Hard tasks	10	130.752	125.530
Mann-Whitney	Easy tasks	7	52.506	49.980
Wilcoxon	synthetic-agent-A	36	0.906	0.907
Wilcoxon	synthetic-agent-B	36	0.901	0.915
Kruskal-Wallis	App Bar	6	79.847	72.730
Kruskal-Wallis	Balance	8	86.767	79.780
Kruskal-Wallis	Promo	4	85.160	81.710
Kruskal-Wallis	Quick Action	8	78.335	68.830
Kruskal-Wallis	Transactions	5	85.732	82.840
Kruskal-Wallis	UI States	5	119.948	125.440

3. Interpretasi

Mann-Whitney: waktu eksekusi task Hard memiliki median 125.530 detik, sedangkan task Easy 49.980 detik. Nilai p = 0.0001028 menunjukkan perbedaan distribusi yang signifikan pada sampel ini. Rank-biserial correlation = 1.000 menunjukkan seluruh nilai Hard lebih tinggi daripada nilai Easy pada data task-level yang digunakan.

Wilcoxon: median akurasi agent A adalah 0.907 dan agent B 0.915. Nilai p = 0.6406, sehingga belum ada bukti yang cukup untuk menyimpulkan perbedaan akurasi berpasangan pada sampel ini. Kesimpulan ini tidak berarti kedua agent pasti sama dalam populasi yang lebih luas.

Kruskal-Wallis: uji omnibus antar-enam component area menghasilkan H = 8.184, df = 5, dan p = 0.1464. Dengan alpha = 0.05, belum ada bukti yang cukup bahwa distribusi waktu eksekusi berbeda antar-area. Karena hasil omnibus tidak signifikan, post-hoc pairwise test tidak dijalankan sebagai bagian dari laporan ini.

Chi-Square: terdapat asosiasi antara difficulty dan status mayoritas task, chi-square = 31.535, df = 2, p = 1.42e-07, dengan Cramer's V = 0.936. Namun, tiga expected cell berada di bawah 5, sehingga hasil perlu dibaca hati-hati dan dapat memerlukan penggabungan kategori atau metode exact pada analisis lanjutan.

Tabel kontingensi Chi-Square

Difficulty	Passed with fixes	Passed
Easy	0	7
Medium	1	18
Hard	10	0

Status task ditentukan dari status mayoritas lima observasi sintetis pada task tersebut.

4. Diagnostics dan keterbatasan

Uji	Diagnostic	Nilai	Catatan
mann_whitney_difficulty_time	Normality assumption	-	Not required; inspect distributions and independence design
wilcoxon_agent_accuracy	Zero paired differences	1.000	Informational; zero differences are omitted by Wilcoxon
kruskal_component_area_time	Smallest group size	4.000	Passes minimum group-size check
chi_square_difficulty_status	Expected cells below 5	3.000	Review sparse expected counts before strong interpretation

Interpretasi dibatasi pada dataset sintetis ini. Data dibuat untuk latihan statistik dan tidak boleh dipresentasikan sebagai data riil Codex, agent AI, aplikasi Android produksi, atau benchmark performa. Hasil signifikan juga tidak membuktikan hubungan sebab-akibat.

5. Reproduksi

Analisis dapat dijalankan ulang dari root repository dengan perintah berikut:

```
python analysis/non_parametric_analysis.py
```

Perintah tersebut membaca data mentah tanpa mengubahnya dan menghasilkan tabel hasil, ringkasan kelompok, tabel kontingensi, diagnostics, serta laporan Markdown di folder outputs/.