Laporan Tugas T-Test

Analisis one-sample, paired, dan independent T-test

Mata kuliah	Statistics for Data Science
Tugas	Analisis T-Test
Nama	Derayan Bima Alamsyah
Dosen	Undang Syaripudin, Ph.D., M.Kom.
Tanggal	7 Oktober 2026

Ringkasan. Tiga jenis T-test yang diminta telah diterapkan pada dataset yang tersedia di repository. One-sample dan independent test menolak hipotesis nol pada alpha = 0.05, sedangkan paired test tidak menolaknya. Semua kesimpulan hanya bersifat deskriptif untuk sampel sintetis ini.

1. Dataset dan metode

Analisis menggunakan data/migration_tasks.csv dan data/migration_observations.csv. Setiap migration task memiliki lima eksekusi sintetis yang deterministik. Untuk pengujian berbasis waktu, lima eksekusi dirata-ratakan berdasarkan ticket_id terlebih dahulu sehingga unit analisisnya adalah task, bukan setiap pengulangan. Paired test mencocokkan akurasi Agent A dan Agent B berdasarkan ticket_id.

Semua pengujian bersifat two-sided dengan alpha = 0.05. One-sample test membandingkan rata-rata execution time dengan referensi pengajaran 75 detik. Paired test menggunakan selisih akurasi Agent A dan Agent B. Independent comparison menggunakan Welch's t-test karena varians yang sama tidak diasumsikan. Effect size dan confidence interval 95% juga dihitung.

> Keterangan data sintetis: execution time, token usage, accuracy, pass rate, dan error count adalah metrik simulasi untuk pembelajaran. Nilai tersebut bukan pengukuran AI-agent nyata, benchmark Codex, pengukuran Android production, atau bukti performa umum.

2. Hasil pengujian

Ringkasan keputusan

Pengujian	Perbandingan	n	t	df	p-value	Keputusan
One-sample T-test	Semua task vs referensi 75 detik	36	2.546	35.00	0.01546	Tolak H0
Paired-samples T-test	Akurasi Agent A vs Agent B	36	0.802	35.00	0.4282	Gagal menolak H0
Independent Welch T-test	Task sulit vs task mudah	10	14.002	12.09	7.801e-09	Tolak H0

Pengujian	Mean A	Mean B/referensi	Selisih	95% CI selisih	Effect size
One-sample	88.026	75.000	13.026	[2.639, 23.413]	Cohen's d: 0.424
Paired	0.906	0.901	0.005	[-0.007, 0.016]	Paired Cohen's d_z: 0.134
Independent Welch	130.752	52.506	78.246	[66.080, 90.412]	Hedges' g: 5.672

Interpretasi

One-sample: rata-rata execution time per task adalah 88.03 detik, atau 13.03 detik di atas referensi 75 detik. Nilai p two-sided = 0.0155, sehingga hipotesis nol ditolak pada alpha = 0.05.

Paired: rata-rata akurasi Agent A adalah 0.906 dan Agent B adalah 0.901. Selisih rata-rata berpasangan adalah 0.0046 dengan p = 0.4282, sehingga belum ada cukup bukti untuk menolak hipotesis nol tentang selisih rata-rata nol.

Independent: task sulit memiliki rata-rata waktu 130.75 detik, sedangkan task mudah 52.51 detik. Nilai p Welch = 7.80e-09, sehingga hipotesis nol tentang rata-rata yang sama ditolak. Hasil ini mencerminkan struktur kesulitan pada data sintetis, bukan benchmark production.

3. Kesimpulan dan reproduksibilitas

Tiga jenis T-test telah diselesaikan. Pada dataset sintetis ini, tingkat kesulitan task berasosiasi dengan execution time, sedangkan perbandingan akurasi agent yang berpasangan tidak menunjukkan perbedaan rata-rata yang signifikan. Kesimpulan ini hanya bersifat deskriptif dan tidak boleh digeneralisasi di luar sampel sintetis ini.

Reproduksi dari root repository: `python analysis/t_test_analysis.py`. Verifikasi: `python -m unittest discover -s tests -v`.